Сравнение Convergent Cross Mapping (CCM) И Bayesian Adaptive Metric Convergent Cross Mapping (BAM-CCM)

Автор: `@in_sh`

октябрь 2026

Аннотация

В работе сравниваются классический Convergent Cross Mapping (CCM), его вариант с обучаемым расстоянием гауссовские процессы с диагональной и полной метрикой, а также BAM-CCM v0.6 и модификация v0.7. Цель – проверить, улучшает ли обучение алгоритма на геометрии пространства состояний точность восстановления временных рядов и даёт ли новая метрика преимущество перед более простыми регрессионными моделями. Рассмотрены 15 семейств синтетических систем, независимые проверки для разных сценариев и тесты на реальных данных.

BAM-MAP v0.6 получил меньшую ошибку RMSE, чем simplex-CCM, в 78 из 90 сравнений (86,7%). В повторном независимом эксперименте средняя RMSE GP-ARD равна 0,7907, исходного BAM-MAP – 0,8057, а модифицированного BAM-Jac – 0,8042.

Оглавление

Аннотация **i**

Введение **1**

1 От классического CCM к BAM-CCM **2**
1.1 Восстановление пространства состояний 2
1.2 Обучаемая глобальная и локальная метрика 2
1.3 Гауссовский процесс и оценка параметров 3
1.4 Байесовский вариант и его ограничения 4

2 Структура экспериментов **5**
2.1 Способ сравнения 5
2.2 Синтетические системы и независимость повторений 5
2.3 Реальные данные и отрицательные контроли 6

3 Результаты тестирования BAM-CCM v0.6 **7**
3.1 Расширенный тест: 78 побед из 90 7
3.2 Проверка на независимых реализациях 8
3.3 Проверка ложного восстановления 9
3.4 Реальные данные 9

4 Модификация v0.7 и контролируемая абляция **11**
4.1 Как отличить эффект метрики от эффекта GP 11
4.2 Повторный эксперимент 11
4.3 Дополнительные проверки: размер библиотеки и реальные данные 13
4.4 Интерпретация абляции 13

Заключение **15**

Литература **16**

Воспроизведение результатов **17**

Введение

Анализ временных рядов часто предполагает, что взаимосвязь переменных можно обнаружить по тому, насколько хорошо одна из них восстанавливается по другой. Однако схожее поведение возникает не только при непосредственном влиянии: причиной может быть общий фактор, периодическое движение или синхронизация. В нелинейной системе важны также значения переменной "из прошлого поэтому методы восстановления пространства состояний представляют особый интерес.

Классический CCM использует состояния, построенные по задержкам наблюдаемого ряда (лагам), и проверяет изменение точности при увеличении обучающей библиотеки [4]. BAM-CCM предлагает заменить фиксированное расстояние обучаемой метрикой и использовать гауссовский процесс (GP) для регрессии. Это меняет не только способ измерения близости, но и сам способ восстановления. Поэтому сравнение исключительно с simplex-CCM не позволяет определить, какая часть конструкции вносит больший вклад.

Цель исследования – сравнить ошибку восстановления классического CCM, GP-ARD, GP-Full, BAM v0.6 и v0.7 на одинаковых данных и проверить обоснованность интерпретации результатов. Оцениваются три гипотезы: (H1) BAM точнее simplex-CCM по RMSE; (H2) локальная метрика улучшает GP-ARD и GP-Full; (H3) байесовское усреднение надёжнее MAP-оценки. Все три требуют сравнения на отложенных данных.

Все представленные ниже значения взяты из результатов экспериментов, сохранённых в проекте. Они относятся к конкретным наборам данных и настройкам, а не ко всем возможным нелинейным динамическим системам.

Глава 1

От классического CCM к BAM-CCM

1.1 Восстановление пространства состояний

Пусть X_t и Y_t – наблюдаемые ряды. По истории Y при размерности вложения E и задержке τ строится вектор

$$\mathbf{m}_Y(t) = (Y_t, Y_{t-\tau}, \ldots, Y_{t-(E-1)\tau})^\top \in \mathbb{R}^E. \tag{1.1}$$

Подход связан с теоремой Такенса, но математические условия этой теоремы нельзя автоматически переносить на нестационарные и зашумлённые финансовые данные [5]. В экспериментах фиксированы $E = 3$ и $\tau = 1$; результат может измениться при другом выборе задержек.

Для тестовой точки $\mathbf{m}_Y(t)$ классический simplex-CCM выбирает $E+1$ ближайших точек библиотеки $\mathcal{L}$ по евклидову расстоянию d_j. Веса и оценка задаются формулами

$$w_j(t) = \frac{\exp[-d_j(t)/d_1(t)]}{\sum_{\ell=1}^{E+1} \exp[-d_\ell(t)/d_1(t)]}, \qquad \widehat{X}_t = \sum_{j=1}^{E+1} w_j(t) X_{t_j}, \tag{1.2}$$

где d_1 – расстояние до ближайшего соседа; при совпадении точек используется отдельная обработка нулевого расстояния. Соседи-точки, которых слишком близки по времени, исключаются по правилу Тейлера $|t - t_j| \le E\tau$. Качество восстановления оценивается корреляцией $\rho = \mathrm{Corr}(X_t, \widehat{X}_t)$ и ошибкой RMSE; при анализе CCM важено наблюдать рост ρ с размером библиотеки для убедительности результатов.

Обозначение `X_from_Y` означает восстановление X по истории Y. Но важно понимать, что высокая ρ или малая RMSE не доказывают, что X причинно влияет на Y: общая причина и синхронизация тоже могут обеспечивать хорошее восстановлние [1].

1.2 Обучаемая глобальная и локальная метрика

Евклидова метрика присваивает всем координатам задержек одинаковый вес и не учитывает их взаимосвязь. Глобальная обучаемая метрика задаётся формулой

$$d_M^2(\mathbf{x}, \mathbf{x}') = (\mathbf{x} - \mathbf{x}')^\top M (\mathbf{x} - \mathbf{x}'), \qquad M = L^\top L. \tag{1.3}$$

Матрица L нижнетреугольная с положительной диагональю. Если она диагональна, модель обучает отдельный масштаб каждой координаты (GP-ARD); если допускаются внедиагональные элементы, учитываются линейные взаимосвязи координат (GP-Full). В `Metric-CCM` используются расстояния, полученные из GP-Full, но сама реконструкция остаётся методом ближайших соседей.

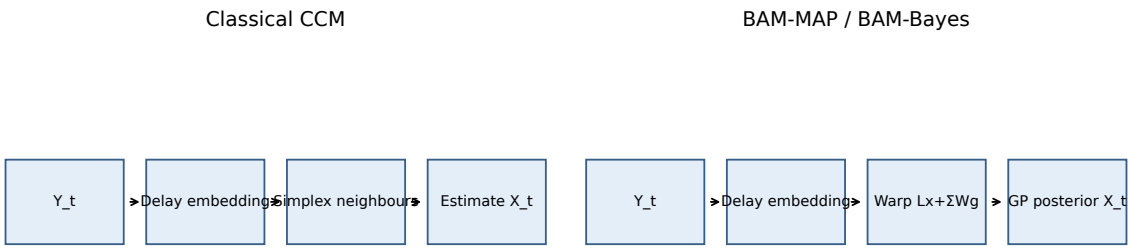


Рис. 1.1: Различие между simplex-CCM и моделями BAM: ближайшие соседи заменяются регрессией с обучаемым ядром.

Локальная версия BAM v0.6 преобразует пространство состояний по правилу

$$\phi_\theta(\mathbf{x}) = L\mathbf{x} + \sum_{r=1}^{K} W_r g_r(\mathbf{x}), \tag{1.4}$$

$$g_r(\mathbf{x}) = \exp\left(-\frac{\|\mathbf{x} - \mathbf{c}_r\|_2^2}{2h^2}\right). \tag{1.5}$$

Центры $\mathbf{c}_r$ и ширина h определяются по обучающей библиотеке; оптимизируются коэффициенты L и W_r. Якобиан отображения равен

$$J_\phi(\mathbf{x}) = L - \sum_{r=1}^{K} \frac{g_r(\mathbf{x})}{h^2} W_r(\mathbf{x} - \mathbf{c}_r)^\top, \qquad M(\mathbf{x}) = J_\phi(\mathbf{x})^\top J_\phi(\mathbf{x}). \tag{1.6}$$

Такая метрика может менять чувствительность к координатам в разных областях пространства. Её положительная полуопределённость следует из вида $J_\phi^\top J_\phi$, но это не гарантирует, что отображение сохраняет различимость всех точек. Дополнительные коэффициенты необходимо оценивать на независимых данных, иначе гибкая модель может подстроиться под шум.

1.3 Гауссовский процесс и оценка параметров

Во всех GP-моделях используется одинаковая форма RBF-ядра

$$k_\theta(\mathbf{x}, \mathbf{x}') = \sigma_f^2 \exp\left[-\frac{1}{2}\|\phi_\theta(\mathbf{x}) - \phi_\theta(\mathbf{x}')\|_2^2\right], \tag{1.7}$$

с независимым нормальным шумом наблюдения $\varepsilon \sim \mathcal{N}(0, \sigma_n^2)$. Поскольку RBF-ядро вычисляется для обеих точек после одного и того же преобразования ϕ, матрица ковариаций остаётся симметричной и положительно полуопределённой. Действительно, для любой конечной выборки $\{\mathbf{x}_i\}$ её матрица Грама совпадает с матрицей обычного RBF-ядра на точках $\{\phi(\mathbf{x}_i)\}$.

Для обучающих входов $Z = (\mathbf{x}_1, \ldots, \mathbf{x}_L)$ и целей $\mathbf{y}$ вводится $C_\theta = K_\theta + (\sigma_n^2 + 10^{-7})I$. Параметры оцениваются по маргинальному правдоподобию GP [3]:

$$\log p(\mathbf{y} \mid Z, \theta) = -\frac{1}{2}\mathbf{y}^\top C_\theta^{-1}\mathbf{y} - \frac{1}{2}\log|C_\theta| - \frac{L}{2}\log(2\pi), \tag{1.8}$$

$$\hat{\theta}_{MAP} = \arg\max_\theta \{\log p(\mathbf{y} \mid Z, \theta) + \log p(\theta)\}. \tag{1.9}$$

Для численной устойчивости решения используется разложение Холецкого, а для MAP — оптимизатор L-BFGS-B и гауссовские априорные штрафы. Предсказательное среднее и дисперсия для тестовой точки имеют вид

$$\mu_* = k_*^\top C_\theta^{-1}\mathbf{y}, \qquad v_* = k_\theta(\mathbf{x}_*, \mathbf{x}_*) + \sigma_n^2 - k_*^\top C_\theta^{-1} k_*. \tag{1.10}$$

По сравнению с simplex-CCM GP использует всю библиотеку и обучаемое гладкое ядро; следовательно, возможное уменьшение RMSE нельзя однозначно отнести к улучшению метрики. Для $E = 3$, $K = 2$ GP-ARD имеет 5 настраиваемых параметров, GP-Full – 8, а локальная модель BAM – 14. Дополнительная гибкость повышает требования к объёму обучающих данных.

1.4 Байесовский вариант и его ограничения

В BAM-Bayes вместо одной MAP-оценки параметры ядра усредняются по приближённому апостериорному распределению. Для этого реализован блочный elliptical slice sampling [2]. Предсказание представляет собой смесь нормальных распределений, а 90%-е интервалы строятся по этой смеси. Важно различать вероятность значения восстанавливаемого ряда и вероятность причинного воздействия: последняя в реализации не вычисляется.

Оценка по MCMC имеет смысл только после проверки смешивания и сходимости цепей. Так же заметим, что результаты для BAM-Bayes рассматриваются только как проверка работающего программного механизма, а не как доказанное преимущество байесовской процедуры.

Глава 2

Структура экспериментов

2.1 Способ сравнения

Для сравнения моделей построены задержанные векторы с $E = 3$, $\tau = 1$ и фиксированным набором тестовых индексов. Данные разбиваются по времени: приблизительно 60% на обучение, 20% на валидацию и 20% на тест. Среднее и стандартное отклонение вычисляются только по обучающему интервалу. Библиотека обычно содержит $L = 65$ точек, равномерно выбранных из обучения; т.е одинаковые точки используются всеми сравниваемыми моделями. В базовых запусках $K = 2$ и для MAP ограничение оптимизатора составляет 65 итераций. В байесовском подходе библиотека меньше ($L = 50$).

Главный критерий – RMSE на выделенном участке:

$$\mathrm{RMSE} = \sqrt{\frac{1}{n}\sum_{t\in\mathcal{T}}(X_t - \widehat{X}_t)^2}. \tag{2.1}$$

Дополнительно рассчитываются MAE и корреляция ρ, а для вероятностной модели – покрытие интервалов и отрицательная логарифмическая плотность прогноза. RMSE приводится в единицах целевой переменной, стандартизованной по train; результат не является прогнозом будущей цены или экономического эффекта.

2.2 Синтетические системы и независимость повторений

Для проверки разнообразных сценариев использованы 15 семейств: связанные логистические отображения, Hénon, Lorenz, Rössler, авторегрессионная и нелинейная связи, связь с задержкой, независимые процессы, общий фактор, синхронизация, гетероскедастический шум и шум с "тяжёлыми"хвостами, смена режимов, неравномерные наблюдения и периодические сигналы. Математические генераторы реализованы в `experiments/generate_synthetic.py`; отдельные описания каждого параметра оставлены в коде, чтобы не дублировать его в отчёте.

Расширенный тест использует 15 семейств, три заранее заданные конфигурации и два направления восстановления – всего $15 \times 3 \times 2 = 90$ сравнений. Конфигурации (β, σ, N) равны $(0, 0.1, 450)$, $(0.2, 0.05, 650)$ и $(0.35, 0.2, 900)$. Поскольку степень связи, шум и длина меняются одновременно, этот набор не подходит для раздельной оценки их влияния. Для Logistic, Independent и Common Driver проведено по десять дополнительных независимых реализаций.

2.3 Реальные данные и отрицательные контроли

На реальных данных рассмотрены семь постановок: потребление энергии Appliances, Bike Sharing по дням и часам и четыре финансовые задачи, объединяющие QQQ, S&P 500, VIX и объёмы торгов. Источники Appliances и Bike Sharing описаны в открытых наборах UCI [7, 6]. Исходники CSV лежат в `original/data`.

Отдельно проверены заведомо независимые процессы, пары с общей причиной и периодические сигналы. Применены циклические сдвиги и анализ временных лагов.

Глава 3

Результаты тестирования BAM-CCM v0.6

3.1 Расширенный тест: 78 побед из 90

В таблице 3.1 показана медиана относительного изменения RMSE BAM-MAP и число сравнений, когда RMSE минимальна. Процент (насколько лучше BAM-MAP) для пары запусков вычисляется по формуле

$$I = 100\,\frac{\mathrm{RMSE}_{base} - \mathrm{RMSE}_{BAM}}{\mathrm{RMSE}_{base}}. \tag{3.1}$$

Положительное значение означает преимущество BAM.

Таблица 3.1: Среднее превосходство BAM-MAP по шести направлениям (seed 42).

Система	n	к CCM, %	к GP-ARD, %	Победы над CCM	Над GP-ARD
common_driver	6	12.477	-4.105	6/6	1/6
coupled_ar	6	8.720	-0.309	6/6	2/6
delayed	6	9.130	-0.225	6/6	1/6
heavy_tailed	6	4.587	-1.905	4/6	1/6
henon	6	10.989	1.466	5/6	4/6
heteroskedastic	6	2.450	-3.385	3/6	1/6
independent	6	7.571	-0.862	5/6	0/6
irregular	6	6.663	-0.791	6/6	2/6
logistic	6	6.089	-1.845	4/6	1/6
lorenz	6	19.551	-7.771	6/6	2/6
nonlinear	6	10.611	-0.671	6/6	1/6
periodic	6	8.588	9.315	4/6	4/6
regime_switch	6	8.242	-1.581	6/6	0/6
rossler	6	13.618	0.565	6/6	4/6
synchronized	6	12.846	-0.179	5/6	3/6

Суммарно BAM-MAP оказался точнее классического simplex-CCM в 78 из 90 случаев, то есть $78/90 \times 100 = 86{,}7\%$. Это доля сравнений, а не снижение RMSE на 86,7%. Напротив, в сравнении с GP-ARD локальная модель заметно реже имела преимущество. Таким образом, замена simplex-регрессии на BAM полезна во многих задачах, хоть и уступает GP.

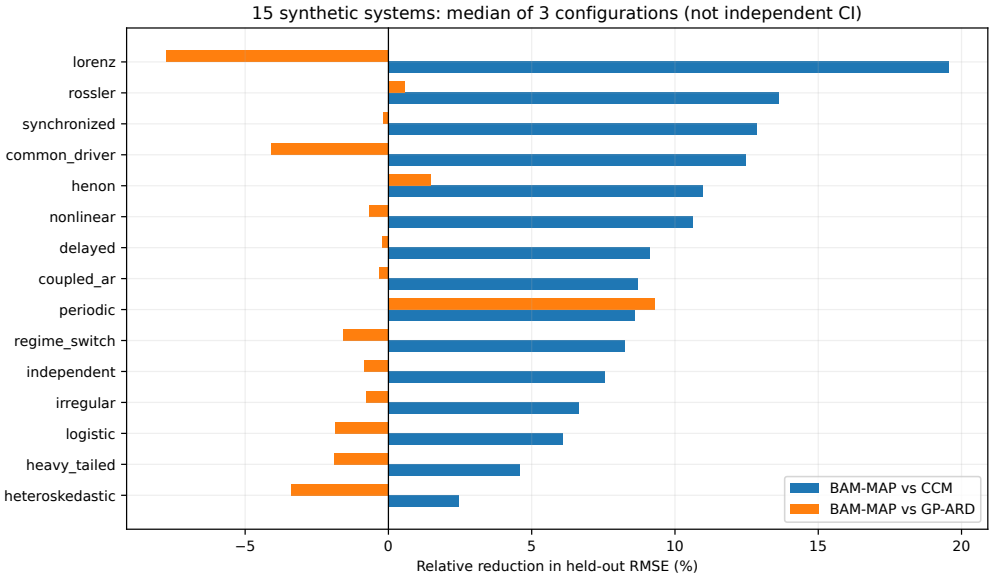


Рис. 3.1: Медианное относительное изменение RMSE BAM-MAP в 15 семействах синтетических систем (в сравнении с базовыми моделями).

3.2 Проверка на независимых реализациях

В трёх семействах Logistic, Independent и Common Driver тест повторён для десяти независимо сгенерированных рядов. Например, относительно CCM среднее относительное улучшение BAM-MAP на Logistic составило 10,84% при восстановлении X из Y (7 побед из 10) и 5,76% в обратном направлении (8 побед из 10). Для Independent соответствующие улучшения составили 6,90% и 11,75%, хотя прямой причинной связи между рядами не было. На данных Common Driver – 6,65% и 5,87%. Из этого следует ключевой вывод: хорошее восстановление на независимых и опосредованно связанных рядах нельзя принимать за установленную причинность.

В тех же опытах BAM-MAP уступал GP-ARD в среднем по большинству направлений. Парные интервалы по независимым траекториям рассчитаны в исходных файлах `experiments/results/`; они не подтверждали общего превосходства использования локальной метрики над GP-ARD.

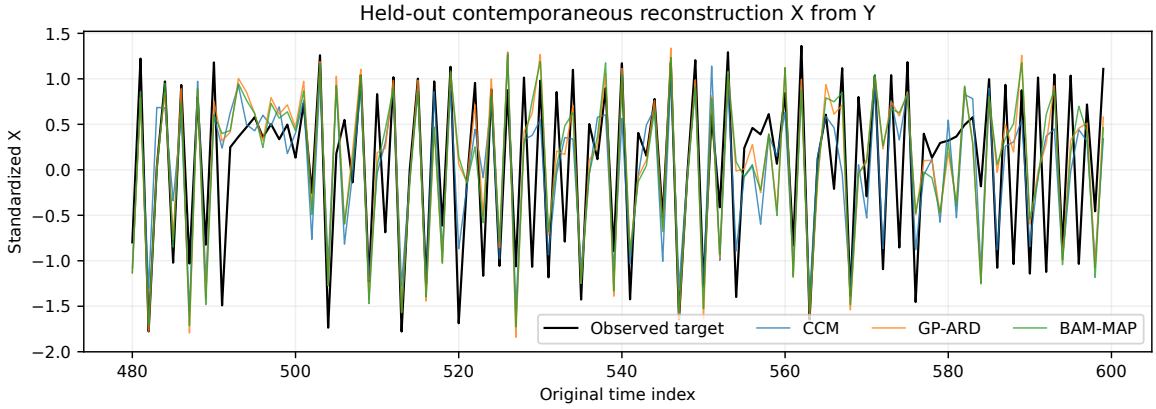


Рис. 3.2: Пример реконструкции тестового участка Logistic: наблюдаемый ряд и оценки моделей.

3.3 Проверка ложного восстановления

Результаты циклических сдвигов показывают, почему высокая корреляция может вводить в заблуждение. В частности, для периодического сигнала корреляции без сдвига достигали 0,989 и 0,985, но сдвиги также давали сопоставимые значения. Для независимых рядов ненулевая корреляция может возникнуть случайно.

Таблица 3.2: Диагностика 99 случайных циклических сдвигов; частота превышений не интерпретируется как калиброванный причинный p-value.

Система	Направление	Наблюдаемое ρ	Сдвигов с $\rho_{shift} \geq \rho_{obs}$
common_driver	X_from_Y	0.187	2/99
common_driver	Y_from_X	0.291	1/99
independent	X_from_Y	-0.153	92/99
independent	Y_from_X	0.060	29/99
logistic	X_from_Y	0.773	0/99
logistic	Y_from_X	0.627	0/99
periodic	X_from_Y	0.989	23/99
periodic	Y_from_X	0.985	48/99

В этой работе мы не будем пытаться разобраться уязвимостью правила «высокая ρ означает прямую связь».

3.4 Реальные данные

Таблица 3.3: Средняя RMSE по двум направлениям восстановления; сценарии не являются независимыми повторениями.

Датасет	CCM	GP-ARD	GP-Full	BAM-MAP
appliances	1.437	1.405	1.404	1.402
bike_day	1.397	1.444	1.458	1.441
bike_hour	0.792	0.785	0.784	0.784
qqq_sp500	0.493	0.411	0.412	0.411
qqq_vix	0.907	0.876	0.903	0.908
qqq_volume	0.971	0.910	0.921	0.922
sp500_volume	0.953	0.919	0.918	0.917

Результаты неоднородны: в задачах QQQ–S&P 500 и QQQ volume GP-модели показывают меньшую ошибку, чем CCM, но в дневном Bike Sharing GP-ARD уступает CCM. BAM-MAP выигрывает не во всех постановках и не всегда превосходит GP-ARD. Так как рассматривается один временной блок на задачу, эти результаты не дают основания утверждать устойчивое преимущество на финансовом рынке.

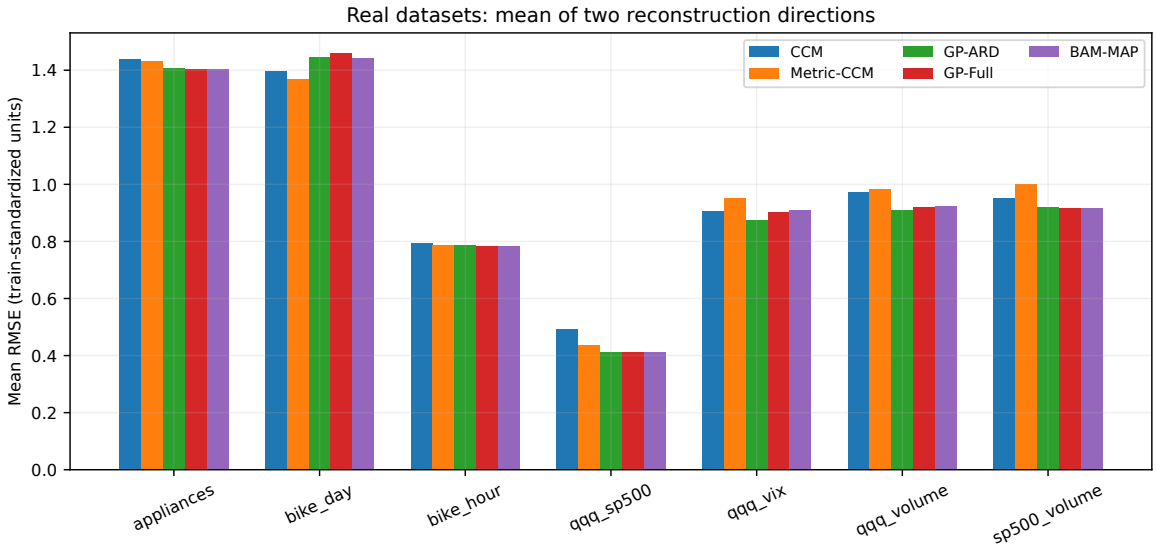


Рис. 3.3: Средняя RMSE по двум направлениям для семи реальных постановок. Разные задачи имеют собственную train-нормировку.

Глава 4

Модификация v0.7 и контролируемая абляция

4.1 Как отличить эффект метрики от эффекта GP

Для версии v0.7 выполнено сравнение внутри одного семейства GP с одинаковыми входами, нормировкой, разделением данных и видом ядра. Рассмотрены шесть моделей: GP-Fixed (евклидова геометрия), GP-ARD (диагональные масштабы), GP-Full (полная линейная метрика), BAM-CCM, BAM-warm (BAM-CCM + несколько приближений) и BAM-Jac (дополнительная регуляризация). Исходная реализация v0.6 при этом не менялась.

BAM-warm запускает локальную оптимизацию из трёх состояний: нулевого, решения GP-ARD и решения GP-Full; выбирается лучший результат на обучающей функции цели. BAM-Jac к отрицательному MAP-логарифму добавляет штраф отклонения локального якобиана от глобального линейного преобразования:

$$R_J(\theta) = \frac{\lambda_J}{2m} \sum_{i=1}^{m} \|J_\phi(\mathbf{x}_i) - L\|_F^2, \qquad \mathcal{L}_{Jac} = -\log p(\mathbf{y} \mid Z, \theta) - \log p(\theta) + R_J(\theta). \tag{4.1}$$

Штраф вычисляется только на обучающей библиотеке; он уменьшает резкие локальные изменения геометрии, но не гарантирует инъективности. На пилотных реализациях с тремя seed оценивались $\lambda_J \in \{0, 2, 20\}$; минимальную валидационную ошибку дал $\lambda_J = 20$. Ни один кандидат в этом пилоте в среднем не превзошёл GP-ARD.

4.2 Повторный эксперимент

После выбора λ_J использованы десять новых seed (не входивших в пилот), шесть систем и два направления восстановления. Результаты приведены в таблице 4.1. Доминирующий эффект в этой проверке – снижение средней RMSE при переходе от GP-Fixed (0,8259) к GP-ARD (0,7907). Добавление полной глобальной метрики повышает RMSE до 0,8013; исходная BAM – до 0,8057. Регуляризация уменьшает ошибку BAM-Jac до 0,8042, но преимущество GP-ARD сохраняется. Разность исходного BAM и BAM-Jac составляет около 0,00155; 95%-й интервал для этой разности $[-0{,}00160; 0{,}00470]$ включает ноль. Следовательно, устойчивое улучшение новой версии относительно исходной не подтверждено.

Таблица 4.1: Отложенный тест: средняя RMSE на 6 системах, 10 новых seed и двух направлениях; ДИ построен по 10 seed-агрегатам.

Модель	p	RMSE	Δ к ARD	95% ДИ для Δ
GP–Fixed	2	0.8259	-0.0353	[-0.0460; -0.0246]
GP–ARD	5	0.7907	+0.0000	[+0.0000; +0.0000]
GP–Full	8	0.8013	-0.0106	[-0.0140; -0.0073]
BAM–original	14	0.8057	-0.0151	[-0.0222; -0.0080]
BAM–warm	14	0.8053	-0.0146	[-0.0210; -0.0083]
BAM–Jac–20	14	0.8042	-0.0135	[-0.0201; -0.0069]

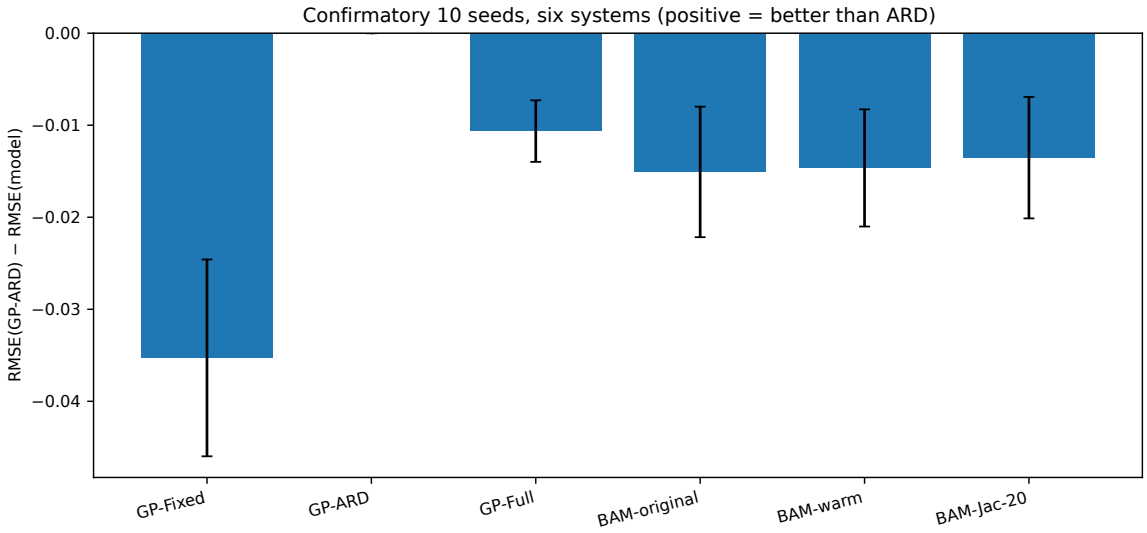


Рис. 4.1: Разность RMSE относительно GP-ARD в контролируемой абляции. Отрицательная разность означает, что сравниваемая модель хуже GP-ARD.

4.3 Дополнительные проверки: размер библиотеки и реальные данные

Чтобы понять роль объёма обучения, выполнен дополнительный эксперимент на четырёх семействах с пятью новыми seed и библиотеками из 40, 65 и 120 точек. В таблице 4.2 приведена разность RMSE(GP-ARD) − RMSE(model); отрицательное значение означает отставание сравниваемого метода. При увеличении библиотеки отставание BAM-Jac

Таблица 4.2: Чувствительность к размеру библиотеки на пяти новых seeds и четырёх семействах: разница RMSE(GP-ARD)−RMSE(model), положительное значение означает преимущество модели.

Библиотека	GP-Full	BAM-original	BAM-Jac
40	-0.0185	-0.0255	-0.0206
65	-0.0062	-0.0183	-0.0119
120	-0.0056	-0.0088	-0.0086

уменьшилось, но не исчезло. Это согласуется с предположением, что локальная модель требует больше данных для оценки дополнительных параметров.

Проверка на семи реальных данных охватила 14 различных задач. BAM-Jac показал меньшую RMSE, чем GP-ARD, в 8 из 14 задач, однако средняя разность RMSE(ARD) − RMSE(BAM-Jac) составила −0,0045. Это не является подтверждением общего преимущества, однако доказываает, что v0.7 может оказаться не хуже GP на реальных данных.

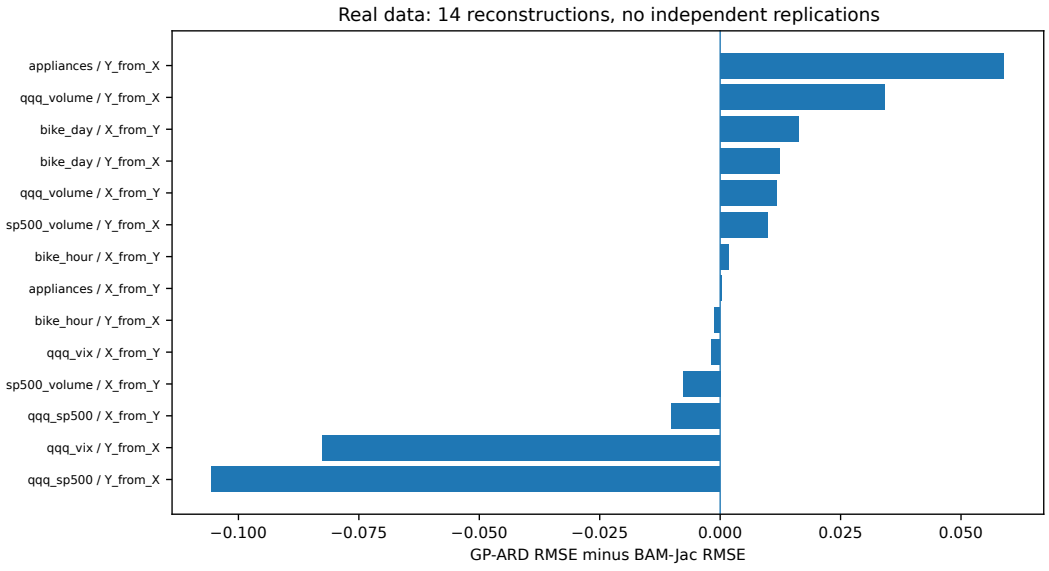


Рис. 4.2: Разность RMSE между GP-ARD и BAM-Jac на семи реальных постановках и двух направлениях.

4.4 Интерпретация абляции

Дополнительные локальные улучшения не дали устойчивого улучшения на рассмотренных данных. Наиболее простое объяснение состоит в том, что при библиотеке из 65 точек

обучаемые глобальные масштабы уже улавливают важную часть структуры, тогда как параметры локальной деформации повышают сложность оценки. Повторные запуски почти не изменили RMSE.

Заключение

Гипотеза H1 подтвердилась в расширенном пилоте: BAM-MAP v0.6 имел меньшую RMSE, чем simplex-CCM, в 78 из 90 сравнениях (87% случаев). Гипотеза H2 не подтвердилась: GP-ARD превзошёл локальные модели по средней RMSE. H3 выглядит достоверной, однако нельзя считать ее доказанной из-за плохой сходимости некоторых цепей MCMC.

Наиболее содержательный результат: BAM-CCM имеет значительное преимущество по сравнению с классическим CCM, однако незначительно уступает более простому и быстрому GP-Full.

Литература

[1] Sarah Cobey и Edward B. Baskerville. «Limits to Causal Inference with State-Space Reconstruction for Infectious Disease». В: *PLOS ONE* 11.12 (2016), e0169050. doi: 10.1371/journal.pone.0169050. url: https://journals.plos.org/plosone/article?id=10.1371/journal.pone.0169050.

[2] Iain Murray, Ryan P. Adams и David J. C. MacKay. «Elliptical Slice Sampling». В: *Proceedings of the Thirteenth International Conference on Artificial Intelligence and Statistics*. Т. 9. Proceedings of Machine Learning Research. 2010, с. 541—548. url: https://proceedings.mlr.press/v9/murray10a.html.

[3] Carl Edward Rasmussen и Christopher K. I. Williams. *Gaussian Processes for Machine Learning*. MIT Press, 2006. isbn: 9780262182539. url: https://gaussianprocess.org/gpml/.

[4] George Sugihara, Robert May, Hao Ye, Chih-hao Hsieh, Ethan Deyle, Michael Fogarty и Stephan Munch. «Detecting Causality in Complex Ecosystems». В: *Science* 338.6106 (2012), с. 496—500. doi: 10.1126/science.1227079. url: https://pubmed.ncbi.nlm.nih.gov/22997134/.

[5] Floris Takens. «Detecting Strange Attractors in Turbulence». В: *Dynamical Systems and Turbulence, Warwick 1980*. Т. 898. Lecture Notes in Mathematics. Springer, 1981, с. 366—381. doi: 10.1007/BFb0091924. url: https://doi.org/10.1007/BFb0091924.

[6] UCI Machine Learning Repository. *Bike Sharing*. Dataset record, accessed 2026-10-28. 2013. url: https://archive.ics.uci.edu/dataset/275/bike+sharing+dataset.

[7] UCI Machine Learning Repository. *Appliances Energy Prediction*. Dataset record, accessed 2026-10-28. 2017. url: https://archive.ics.uci.edu/dataset/374/appliancesenergyprediction.

Воспроизведимость

Код для v0.6 находится в `original/bam_ccm.py`, модификация v0.7 – в `modified/bam_ccm_v07.py`, а код генераторов и тесты – в `experiments/`. Исходные данные хранятся в `original/data/`, сохранённые метрики и конфигурации – в `experiments/results/`. Запуск выполняется так (Python 3.10+):

```
python3 -m venv .venv
source .venv/bin/activate
python -m pip install -r original/requirements.txt
python original/bam_ccm.py -self-test
python -m pytest original/tests experiments/tests -q
python experiments/run_all.py -quick
python experiments/run_metric_research.py -phase pilot
python experiments/run_metric_research.py -phase confirm
```

Файл `experiments/results/metric_research/selection.json` фиксирует выбранную регуляризацию. Численные значения в основных таблицах взяты из соответствующих CSV.